仮説条件付き実験選択は SBML の機構回復にも効くか（第 2 報）：LLM-AutoSciLab の公式モジュールを Antimony の仮説で SciGym に繋ぎ、10 件で ReAct と比べる事前登録研究

Anonymous authors
Paper under double-blind review

Abstract

LLM-AutoSciLab (Kabra et al., 2026) は、複数の候補機構を明示的に持ち、候補どうしの予測が最も食い違う条件を次の実験に選ぶ閉ループの発見枠組みである。前研究（auto-res2/scigym-autoscilab、同 v3）は SciGym (Duan et al., 2025) の反応回復課題にこの枠組みを移植して 137 件で検証し、反応の構造（RMS）では公式 ReAct エージェントを上回ったが軌道誤差（STE）では及ばず、仮説条件付きの実験選択は測れる差を与えなかった。事後分析では、移植が速度則を 3 型に固定していたこと（論文の LLM は式を自由に書く）が主因と判断した。本研究は移植を書き直す: 上流の公式モジュール（`EnsembleAgent`、`HypothesisDistribution`、`FalsificationSelector`、`ExperimentStore`、`LLMMemory`、LLM クライアント）をそのまま使い、Python 式が前提の部分だけをサブクラスで差し替え、仮説は Antimony の反応ブロックとして LLM が反応・速度則・定数を自由に書く。データ（SciGym-small から等間隔に 10 件）、実験の種類（初期濃度の変更）、正解モデルへの問い合わせ予算（20 回）、評価（公式 Evaluator の STE / RMS / NTS）、LLM（3 run とも openai/gpt-6-luna）は固定し、比較相手は SciGym 公式 ReAct、アブレーションは実験選択だけを仮説と無関係にした同じ部品である。実験前に 3 つの主張を凍結する: 手法 run の平均 STE が ReAct より 0.02 以上低い（c1）、アブレーションの平均 STE が手法 run より 0.01 以上高い（c2）、ReAct の RMS F1 が手法 run より 0.02 以上低い（c3）。10 件では差の標準誤差が 0.1 程度あり、判定は規則どおり導くが統計的な力は弱い。

1 はじめに

LLM に科学的発見のサイクル全体を行わせる研究には、二つの流れがある。一つは SciGym (Duan et al., 2025) のように、LLM エージェントが摂動実験を要求し、返ってきたデータを解析し、機構を提出するまでを一つの会話の中で行わせ、その出来を測るベンチマークである。もう一つは LLM-AutoSciLab (Kabra et al., 2026) のように、発見を「進化する仮説集合の上での逐次実験計画」として定式化し、仮説を一つに絞らずに複数の候補機構を持ち、候補どうしの予測が最も食い違う条件を次の実験に選ぶ枠組みである。

LLM-AutoSciLab は、候補機構の食い違いに基づく実験選択（仮説条件付き獲得）が固定予算のもとでサンプル効率を改善すると主張し (Kabra et al., 2026, s2.p2)、アブレーションではこの部品を外すと全ベンチマークで大きく低下したと報告している (Kabra et al., 2026, s2.p7)。しかし評価に使われたオラクルは、入力を与えると一つの値を返すノイズのない黒箱関数である (Kabra et al., 2026, s2.p5)。公式リポジトリに含まれる SciGym 向けのアダプタも、SBML の機構復元ではなくスカラーのシミュレータ応答を最適化するものだと自ら述べており (Kabra et al., 2026, s2.p14)、SciGym の課題そのもの（全種の時系列を観測し、欠けた反応を SBML として提出する）には当てられていない。著者らも、性能が LLM の仮説の質とパーサ・改良バックエンドの対応範囲に依存することを限界として挙げている (Kabra et al., 2026, s2.p8)。一方 SciGym の側では、公式の ReAct エージェント (Duan et al., 2025, s1.p3) は実験の選び方に原理を持たない。論文は、初期濃度の変更という摂動が「戦略的に設計されれば」種の関係・反応の型・速度則・反応速度について多くの情報を与えると述べて

いる (Duan et al., 2025, s1.p8) が、何をもって戦略的とするかはエージェントの推論に委ねられている。

AIRAS の前研究（auto-res2/scigym-autoscilab と同 v3）は、この二つを接続する最初の試みだった。LLM-AutoSciLab の獲得則と LLM クライアントを公式コードから借り、SBML 固有の部分を自前のループ（約 850 行）で書き、速度則を質量作用・Michaelis–Menten・Hill の 3 型に固定して、137 件で SciGym 公式 ReAct と比べた。結果は、反応の構造の回復（RMS F1）では手法が上回ったが、軌道誤差（STE）では ReAct に及ばず（差 +0.098 と +0.094）、実験選択を仮説と無関係にしても STE は変わらなかった。事後分析では、完走した 134 件のうち 43 件でフィット誤差（log 濃度の RMSE）が 1 を超え、フィット誤差と構造の正しさがほぼ無相関であり、本研究の文法では正解の速度則（差の形、多項式、Hill 項の積）を表せないことが主因と判断した。この 3 型への固定は移植側で入れた制約であり、LLM-AutoSciLab の手法が課すものではない。

本研究はその移植を書き直す。上流の公式モジュールをそのまま使い、Python 式が前提になっている部分だけをサブクラスで差し替え、仮説は Antimony の反応ブロックとして LLM が反応・速度則・定数を自由に書く。問いは前研究と同じ「仮説条件付き獲得は、時系列が観測され SBML を提出する機構回復でも効くか」である。本研究は 137 件ではなく等間隔に選んだ 10 件で行う小規模の検証で、判定の統計的な力は弱い。判定は AIRAS の事前登録の枠組みに従い、仮説・判定基準・予測区間・実行条件を実験前に記録へ凍結し、実験後は計測値だけを流し込む。

2 関連研究

SciGym. SciGym (Duan et al., 2025) は BioModels 由来の SBML モデルから反応を取り除いたものをエージェントに渡し、エージェントは初期濃度を変えた摂動実験を要求し (Duan et al., 2025, s1.p4)、Python で解析し、最終的な SBML を提出する。提出は任意の時点で行え、反復数の上限は 20 である (Duan et al., 2025, s1.p1)。提出モデルが無効なら 3 回までのデバッグ反復が許され、それでも無効なら不完全モデルのまま採点される (Duan et al., 2025, s1.p2)。評価指標は、全種の時系列の対称平均絶対パーセント誤差である STE (Duan et al., 2025, s1.p5)、反応物と生成物の集合が一致した反応の F1 である RMS（修飾子まで要求する厳格版もある）(Duan et al., 2025, s1.p6)、種間の相互作用の F1 である NTS (Duan et al., 2025, s1.p7) の 3 つである。論文は計算資源の制約から small split の 137 件で 6 モデルを評価した (Duan et al., 2025, s1.p9)。提出 SBML の速度則に制限はなく、エージェントは libSBML で任意の数式を書く。

LLM-AutoSciLab. LLM-AutoSciLab (Kabra et al., 2026) は、既存の LLM による発見システムの多くが表現固定かつ受動的で、事前に集めた静的データの上で事後的に仮説を生成・改良するにとどまる (Kabra et al., 2026, s2.p3) と指摘し、仮説を機構レベルの対象としてオンラインの実験選択に使う。1 ラウンドは、small モデルが候補仮説を K 個ずつ並列にサンプルし（論文設定 $K = 5$ (Kabra et al., 2026, s2.p9)）、構造の骨格でクラスタして、クラスタ分布のエントロピーの変化が 0.1 を下回るか 20 個に達したら止め (Kabra et al., 2026, s2.p10)、large モデルがそれを本命・対抗案・探索領域に整理する仮説生成、候補機構の予測が最も食い違う点を選ぶ実験選択 (Kabra et al., 2026, s2.p6)、新データで候補の定数を合わせ直しブートストラップで確信度を測る改良からなる。確信度が閾値（論文設定 0.9）を超えると不確実性サンプリングによる改良モードに切り替わる (Kabra et al., 2026, s2.p12)。論文は主モデルに GPT-4o-mini、small モデルに Qwen2.5-7B-Instruct を用い (Kabra et al., 2026, s2.p4)、アンサンブルのサンプリング温度は 1.0 である (Kabra et al., 2026, s2.p13)。公式コードでは、仮説は Python 式の文字列で、数値リテラルを置換した骨格でクラスタされ (Kabra et al., 2026, s2.p28)、Python 式として評価できない仮説はサンプリング時に捨てられる (Kabra et al., 2026, s2.p29)。

3 仮説と予測

以下は記録（record.json）から生成された仮説・主張・判定基準・予測区間の一覧である。実験後は Observed と Verdict が計測値から埋められる。

Hypothesis 1. LLM-AutoSciLab の仮説条件付き獲得（候補機構の予測が最も食い違う実験を選ぶ）は、著者らが評価したスカラー応答のオラクル（NewtonBench / ActiveSciBench）

の外でも機構回復を改善する。具体的には、全種の濃度時系列が観測され SBML を提出する SciGym-small から等間隔に選んだ 10 件の反応回復課題で、同じ gpt-6-luna を主モデルに使ったとき、SciGym 公式の ReAct エージェント（実験を自由記述の推論で選ぶ）より低い STE と高い RMS を出し、その改善は実験選択則によるものである。(Kabra et al., 2026, s2.p2, s2.p3, s2.p5, s2.p8, s2.p14), (Duan et al., 2025, s1.p3, s1.p8)

Claim 1 SciGym-small から等間隔に選んだ 10 件の平均 STE（trajectory_smape）は、LLM-AutoSciLab の部品で組んだ run（autoscilab-luna）の方が SciGym 公式 ReAct エージェント（react-luna）より 0.02 以上低い。(Kabra et al., 2026, s2.p1, s2.p2, s2.p6, s2.p9, s2.p10, s2.p11, s2.p12, s2.p13, s2.p15, s2.p16, s2.p19, s2.p22, s2.p23, s2.p24, s2.p26, s2.p27, s2.p28, s2.p29, s2.p32, s2.p33, s2.p34, s2.p35, s2.p36, s2.p37), (Duan et al., 2025, s1.p4, s1.p5, s1.p10, s1.p12) *Rationale:* h1 の中心。同じ主モデル・同じ実験予算・同じ 10 件・同じ公式 Evaluator で、手法だけを替えたときの差が STE に出れば、仮説条件付きの閉ループが SBML の機構回復にも効くという h1 の主張の直接の証拠になる。*Criterion:* `autoscilab-luna.trajectory_smape` − `react-luna.trajectory_smape` ≤ -0.02. *Prediction:* $[-0.15, 0.05]$ (137 件での前研究: 同じ gpt-6-luna の公式 ReAct は STE 0.2151（auto-res2/scigym-autoscilab）/ 0.2185（auto-res2/scigym-autoscilab-v3）、速度則を 3 型に固定した前の移植は 0.3133 / 0.3125（差 +0.098 / +0.094）。速度則を自由にした本研究ではその差が縮むと見るが、10 件平均の差の標準誤差は 0.1 程度（1 件の STE の標準偏差 ≈ 0.27）なので、−0.15〜0.05 と置く。). *Observed:* 0.0169719. *Verdict:* refuted.

Claim 2 同じ部品で実験選択だけを仮説と無関係にした autoscilab-nohyp-luna の平均 STE（等間隔に選んだ 10 件）は、autoscilab-luna より 0.01 以上高い。(Kabra et al., 2026, s2.p7, s2.p11, s2.p22) *Rationale:* h1 の「改善は実験選択則によるもの」の部分。論文で最も効いた部品（s2.p7）を外した run との差が出れば、c1 の差が仮説生成やフィットではなく仮説条件付き獲得に帰せられる。*Criterion:* `autoscilab-nohyp-luna.trajectory_smape` − `autoscilab-luna.trajectory_smape` ≥ 0.01. *Prediction:* $[-0.08, 0.1]$ (137 件での前研究ではアブレーションとの差は +0.005 で判定線に届かなかった。論文の Figure 4（s2.p7）は大きな低下を報告する。10 件では差の標準誤差が 0.1 程度なので − 0.08〜0.10 と置く。). *Observed:* -0.0108633. *Verdict:* refuted.

Claim 3 SciGym 公式 ReAct エージェント（react-luna）の RMS（修飾子なしの reaction_f1、等間隔に選んだ 10 件）は、autoscilab-luna より 0.02 以上低い。(Duan et al., 2025, s1.p1, s1.p2, s1.p3, s1.p4, s1.p6, s1.p10, s1.p11) *Rationale:* h1 の RMS の部分。STE は軌道の近さしか見ないので、反応の構造が実際に回復されているかは RMS で確かめる。react-luna はこの claim の run であると同時に c1 の比較対象でもある。*Criterion:* `react-luna.reaction_f1` − `autoscilab-luna.reaction_f1` ≤ -0.02. *Prediction:* $[-0.25, 0.05]$ (137 件での前研究で ReAct の reaction_f1 は 0.3971 / 0.3443、移植は 0.4580 / 0.4558（差 − 0.061 / − 0.112）。構造の回復は速度則の文法に依存しない。10 件では差の標準誤差が 0.1 程度なので − 0.25〜0.05 と置く。). *Observed:* -0.0348052. *Verdict:* supported.

Assumed, so that the claims together imply Hypothesis 1:

- STE / RMS / NTS（SciGym 公式 Evaluator、airas-eval scigym_small）が機構回復の良さを表す（c1, c2, c3）
- アダプタが SciGym の設定を LLM-AutoSciLab の手法に写す仕方（仮説 = 不完全モデルに足す反応の集合 + 速度則、実験 = 初期濃度の変更、食い違い = 候補 SBML の濃度時系列の対数分散）が手法の意図を保っている（c1, c2, c3）
- 上流コード（scientific-discovery/LLM-AutoSciLab @351aae7、h4duan/SciGym @88a7b93）はそれぞれの論文を実装している（c1, c2, c3）
- knob の一覧（design の arguments）は、コードから列挙できた範囲を超えて完全である（c1, c2, c3）
- Vercel AI Gateway が返すモデル（openai/gpt-6-luna）はその名前のモデルである（c1, c2, c3）
- LLM のサンプリングは非決定的であり、1 回の run の差は再現時にずれうる（c1, c2, c3）
- Seyval（RIKYU の BYO Slurm）の実行記録と git 履歴は正しい（c1, c2, c3）

- ReAct の max_iterations=20 と AutoSciLab のオラクル問い合わせ 20 回を同じ実験予算とみなす（ReAct の反復にはコード実行だけの反復も含まれるので、ReAct の実験回数は 20 以下になる）（c1, c3）
- Antimony と SBML の相互変換（tellurium / libantimony）が機構を変えない。Antimony は速度則に現れる非反応物の種を自動で修飾子にする（c1, c2, c3）
- 10 件は 137 件の代表であり、10 件での差が母集団の差を反映する（c1, c2, c3）

判定基準と予測区間の根拠. マージンは前研究と同じ（c1 0.02、c2 0.01、c3 0.02）である。前研究の 137 件では、同じ openai/gpt-6-luna の公式 ReAct は平均 STE 0.2151（scigym-autoscilab）と 0.2185（同 v3）、修飾子なしの RMS F1 は 0.3971 と 0.3443 で、3 型に固定した移植は STE 0.3133 / 0.3125、RMS F1 0.4580 / 0.4558 だった。本研究は速度則を自由にしてフィット誤差の大きい件が減ることを見込むが、10 件では 1 件の STE の標準偏差（約 0.27）から平均の標準誤差が約 0.085、差の標準誤差が約 0.12 と、マージンより大きい。予測区間はそのため、前研究の実測を中心に ± 0.1 程度の幅で置いた（c1: $[-0.15, 0.05]$、c2: $[-0.08, 0.10]$、c3: $[-0.25, 0.05]$）。判定は規則どおり導くが、支持・反証のどちらも 10 件の差が偶然で説明できる範囲にあり得る。NTS、修飾子ありの RMS、提出数、1 件あたりの実験回数、トークン数は同じ実行から表として報告するが、判定には用いない。

4 方法

課題と固定するもの. 各件は真の SBML、反応をすべて取り除いた不完全な SBML、シミュレーション条件（SED-ML）からなる。SciGym 公式コードの `Experiment.call_simulator` (Duan et al., 2025, s1.p12) は `ExperimentConfig` を受けて `ExperimentResult` を返す。本研究ではこの呼び出しを正解モデルに触る唯一の口とする。摂動は論文と同じく初期濃度の変更 (Duan et al., 2025, s1.p4) である。観測する種を指定しない呼び出しでは全種の時系列が返る（SciGym 公式コードの振る舞い）。3 つの run すべてで、この問い合わせを 1 件あたり最大 20 回に揃える。提出 SBML は airas-eval の `scigym_small` パック（SciGym 公式の Evaluator をそのまま包んだもの）で採点する。

比較相手: SciGym 公式 ReAct（run `react-luna`）. SciGym 公式コードのベンチマーク実行の入口は `run_benchmark(self, model: LLM)` である (Duan et al., 2025, s1.p11)。本研究はこの Controller を無改変で用い、LLM は `scigym.api.api.LLM` のサブクラスとして Vercel AI Gateway の OpenAI 互換エンドポイントを呼ぶアダプタだけを書く。反復数の上限 20 は論文と同じである (Duan et al., 2025, s1.p1)。無効な提出に対するデバッグ反復 3 回も論文と同じである (Duan et al., 2025, s1.p2)。temperature 1.0 は SciGym 公式コードの既定値である。SciGym の反復にはコード実行だけの反復も含まれるため、ReAct の実験回数は 20 以下になる。

手法: LLM-AutoSciLab の公式モジュール + SciGym 用アダプタ（run `autoscilab-luna`）. 仮説は Antimony（SBML のテキスト形式）の反応ブロックで表す。LLM は反応（反応物・生成物・可逆性・化学量論）と速度則（種と名前付き定数の任意の数式）と定数の値を自由に書き、不完全モデルを Antimony にした末尾にそのブロックを足して SBML に戻す。速度則の形は制限しない。種や区画への代入、既知でない種、速度則の無い反応、既定条件でシミュレーションが通らないブロックは無効として捨てる（公式コードが Python 式として評価できない仮説を捨てる (Kabra et al., 2026, s2.p29) のに当たる）。論文 Algorithm 1 の各段階と公式モジュールの対応は次のとおりである。

- 仮説生成（GenHyp）: 公式 `EnsembleAgent.run_round` (Kabra et al., 2026, s2.p26) をそのまま呼ぶ。small モデルの $K = 5$ 並列サンプル (Kabra et al., 2026, s2.p9) は公式 `EnsembleClient.complete_json_k`、large モデルの整理は公式 `synthesize_proposal` (Kabra et al., 2026, s2.p37) と `LLMClient.complete_json`（上流のスキーマと prompt のまま）である。ただし `sample_hypothesis_distribution` と `_sample_adaptive` の 2 メソッドはサブクラスで上書きする。上流はサンプルした仮説を `_filter_valid_expressions` に通す (Kabra et al., 2026, s2.p29)。この関数は仮説を Python 式として評価するので、Antimony のブロックには使えない。上書き版は上流の prompt 生成関数をそのまま使い（課題と Antimony の書き方はオラクル役の説明文として入る）、

出力スキーマだけ Antimony 用に替え、有効な候補を canonical 文字列（反応を反応物・生成物・速度則の順に並べ、定数を出現順に付け直したもの）にして公式 `HypothesisDistribution.from_expressions` (Kabra et al., 2026, s2.p27) に渡す。骨格（数値を置換した文字列 (Kabra et al., 2026, s2.p28)）によるクラスタ、エントロピー、適応サンプリングの停止則（エントロピーの変化が 0.1 未満か 20 個 (Kabra et al., 2026, s2.p10)、公式既定値 (Kabra et al., 2026, s2.p30, s2.p31)）は上流のままである。仮説集合（最大 8）は large の本命（Antimony として有効なら）、クラスタの代表（大きい順）、これまでの最良からなる。

- 定数の当てはめ（RefineHyp）: 本研究のコード。仮説が足した定数を、これまでの実験の濃度時系列（等間隔 50 時点、log スケール）に対して scipy で最小二乗フィットする。公式の `EquationLearner.fit` は PySR の記号回帰でスカラー目標を扱うため使えない。
- 実験選択（Acquire）: 公式 `FalsificationSelector.select` (Kabra et al., 2026, s2.p22) をそのまま呼ぶ（候補点 2000 (Kabra et al., 2026, s2.p15)、多様性 0.3 (Kabra et al., 2026, s2.p16)、1 反復 4 点 (Kabra et al., 2026, s2.p19)）。渡す仮説分布は `HypothesisDistribution` のサブクラスで、`compute_disagreement` だけを「候補 SBML を SciGym の `Simulator` で回した全種 × 50 時点の log 濃度の候補間分散」に上書きする（上流は Python 式のスカラー予測の log10 標準偏差）。オラクル役は `BaseOracle` のサブクラスで、変えてよい種とその初期濃度の範囲（既定値の 0.2〜5 倍）を返す。探索領域は large の提案（上流の `SearchRegion`）を許可範囲に切り詰めたものである。
- 問い合わせ: オラクル役の `run` から SciGym の `Experiment.call_simulator` へ。結果は `OracleResult` のサブクラス（全種 × 全時刻の軌道を持つ。上流の `measurement` はスカラー (Kabra et al., 2026, s2.p34)）として公式 `ExperimentStore` に入れる。prompt 用の表 (Kabra et al., 2026, s2.p33) だけ軌道の要約（5 時点 × 全種）に上書きする。候補 SBML の試走はオラクルを通らず、予算を消費しない。
- 確信度（ConfGate）: 公式 `learner.py` の定義 (Kabra et al., 2026, s2.p35)（実験を復元抽出して再フィットし、予測の変動係数の平均を 1 から引く）と R^2 の門 (Kabra et al., 2026, s2.p36) を本研究のコードで計算する（上流の実装は PySR を再学習する private メソッド）。0.9 以上なら改良モード (Kabra et al., 2026, s2.p12): スコアだけを「本命のブートストラップ再フィット間の軌道分散」に替え、選択と多様性は同じ `FalsificationSelector.select` を使う。
- メモリ: 公式 `LLMMemory` をそのまま使い、反復ごとに最良候補とそのフィット値・確信度を記録して次の prompt に入れる。
- 提出: 予算を使い切ったら、フィット誤差が最小の候補を全実験で再フィットし、定数を書き込んだ SBML を提出する。妥当な候補が無い件は提出なし。

ループ本体は本研究のコードで、上の部品を順に呼ぶだけである（公式の `DiscoveryLoop.run` はスカラーの実験履歴・PySR・スカラーのオラクルを内蔵した一枚岩で、差し替え口が無い）。候補 SBML のシミュレーションは、公式の子プロセス管理 `_JsonWorker` のサブクラスで別プロセスに出す。上流の `request` は子プロセスの stdout を `readline` で読む (Kabra et al., 2026, s2.p32)。この読み取りには時間切れが無いので、サブクラスでバッチごとの時間切れを足す（LLM が出した候補は硬い ODE になりやすく、C ライブラリ内で止まると Python のシグナルでは戻せないため）。worker スクリプトは本研究のコードである（公式の `scigym_worker.py` は 3 種の初期濃度から 1 種の最終値を返す縮約 (Kabra et al., 2026, s2.p14) で、全種 × 全時刻を返すには中身の改変が要る）。

アブレーション（`run autoscilab-nohyp-luna`）. 同じ部品・同じモデル・同じ予算・同じ 10 件で、`FalsificationSelector.select` に渡す食い違いスコアを全候補点で 0 にする。貪欲選択は多様性項だけで点を選ぶので、実験は仮説と無関係に濃度空間を埋める配置になる。論文は仮説条件付き獲得を外すアブレーションで全ベンチマークの性能が大きく低下したと報告しているが (Kabra et al., 2026, s2.p7)、その実装の詳細は述べていないので、ここでの実装は本研究が対応させたものである。

記録と検証. 記録には SciGym（コミット 88a7b93）と LLM-AutoSciLab（コミット 351aae7）のコードスナップショットを固定し、手法の各段階について「どの上流の関数をそのまま使うか」「どこをサブクラスで上書きするか」「本研究のコードになる段階はどの上流の関数を検討

Table 1: SciGym-small から等間隔に選んだ 10 件での比較。STE は低いほど、RMS / NTS は高いほどよい。mean_experiments は 1 件あたりの正解モデルへの問い合わせ回数。

	STE ↓	RMS F1	RMS F1 (w/ mod.)	NTS F1	valid subm.	mean exp.	input tok.	output tok.
SciGym ReAct (gpt-6-luna)	0.1622	0.4440	0.2900	0.4548	10	10.9	3067974	176586
LLM-AutoSciLab loop (gpt-6-luna)	0.1792	0.4788	0.2660	0.4903	10	20.0	3689905	2168301
same loop, acquisition without hypotheses	0.1684	0.5091	0.3220	0.5164	10	20.0	3499042	2061055

しなぜ使えないか」を設計に書く。各 run の design には上流関数の引数（候補点 2000、多様性 0.3、`select` の n = 4、`EnsembleClient` の k = 5・temperature 1.0・max_tokens 4096、`LLMClient` の max_completion_tokens 8192、`EnsembleAgent` の adaptive・k_max 20・stability_threshold 0.1、ReAct の max_iterations 20・eval_debug_rounds 3・temperature 1.0）を宣言し、実行時の観測フックが実際の呼び出しと読み込んだ上流ファイルのハッシュを記録して記録の宣言と突き合わせる。凍結の前に sanity モードで 5 つの条件を機械的に確かめる: コードに速度則の型の列挙が無いこと、任意の速度則の Antimony が SBML になり回ること、同じ構造で定数だけ違う仮説が同じクラスタになること、候補の試走が予算を消費しないこと、改良モードのスコアがブートストラップ再フィット間の分散でアブレーションのスコアが 0 であること。

5 実験設計

データと評価. SciGym の small split 137 件を id 順に並べ、等間隔に 10 件（先頭から 13 件おき）を選ぶ。3 run とも同じ 10 件である。評価は airas-eval `scigym_small` の STE（`trajectory_smape`）、RMS F1（`reaction_f1`、修飾子なし）、修飾子ありの RMS F1、NTS F1（`topology_f1`）。

run. `react-luna`（SciGym 公式 ReAct、openai/gpt-6-luna、最大 20 反復）、`autoscilab-luna`（手法、large = small = openai/gpt-6-luna、問い合わせ 20 回、1 反復 4 実験）、`autoscilab-nohyp-luna`（アブレーション、食い違いスコア 0）。run と主張の対応は、c1 ← `autoscilab-luna`（比較対象は `react-luna`）、c2 ← `autoscilab-nohyp-luna`（比較対象は `autoscilab-luna`）、c3 ← `react-luna`（比較対象は `autoscilab-luna`）である。

LLM. 3 run とも openai/gpt-6-luna。論文は主モデルに GPT-4o-mini、small モデルに Qwen2.5-7B-Instruct を用いた (Kabra et al., 2026, s2.p4) が、本研究ではこの非対称を再現せず、small モデルの K = 5 並列サンプルも同じモデルを temperature 1.0 (Kabra et al., 2026, s2.p13) で引く。

予算の揃え方. 3 run とも正解モデルへの問い合わせを 1 件 20 回で揃える。ReAct の 20 反復にはコード実行だけの反復も含まれるので、ReAct の実験回数は 20 以下になる。両方で 1 件あたりの実験回数とトークン数を記録し、表に出す。

計算環境と手順. RIKYU（理研 R-CCS、aarch64）上で Seyval の BYO Slurm ジョブとして実行する。1 run = 1 ジョブ（cpu-general、1 ノード、上限 4 日）、1 件 1 プロセス、10 件を並列。手順は sanity（1 件、予算 9 / 2 反復、上の 5 条件の確認を含む）→ 凍結 → full（10 件 × 3 run）。pilot は置かない。sanity の出力は証拠にせず、full は凍結コミットの子孫で実行する。引用判定のモデルは前研究と同じ gpt-4.1 である。

6 結果

3 run とも 10 件すべてが完走し、提出があった（有効提出数は表 1）。autoscilab の 2 run は全件で正解モデルへの問い合わせをちょうど 20 回使い（20 回 / 件）、ReAct は平均 10.9 回だった。表 1 に 3 run の指標を示す。各 claim の判定は claims.tex（§3）に記録の値から機械的に導かれている。

c1（STE: AutoSciLab ループ vs ReAct）. 平均 STE は autoscilab-luna が 0.179221、react-luna が 0.162249 で、差は +0.017 である。判定線（−0.02 以下）には届かず、c1 は反証された。予測区間 $[-0.15, 0.05]$ には入っている。

c2（STE: アブレーション vs AutoSciLab ループ）. 平均 STE は autoscilab-nohyp-luna が 0.168357 で、autoscilab-luna より 0.011 低かった（差 -0.011）。判定線（+0.01 以上）に届かず、c2 は反証された。差は予測区間 $[-0.08, 0.10]$ の内側にある。仮説条件付き獲得を外しても STE は悪化せず、10 件では逆にわずかに良かった。

c3（RMS: ReAct vs AutoSciLab ループ）. 修飾子なしの RMS F1 は react-luna が 0.443983、autoscilab-luna が 0.478788 で、差は -0.035 である。判定線（−0.02 以下）を満たし、c3 は支持された。予測区間 $[-0.25, 0.05]$ には入っている。修飾子ありの RMS F1 と NTS F1 も表 1 のとおりで、修飾子ありの RMS F1 は ReAct の方がわずかに高く、NTS F1 はループの方が高い。

前研究との比較. 速度則を 3 型に固定していた前研究（137 件）では、同じ ReAct との STE の差が +0.098 / +0.094 だった。速度則を自由にした本研究の 10 件では差が +0.017 で、差は 5 分の 1 以下に縮んだが符号は変わらず、ReAct を下回るには至らなかった。ただし件数も件の集合も違うので、この比較は目安にとどまる。

計算資源. 入力トークンは 3 run で同程度だが（表 1）、出力トークンは ReAct に対してループが約 12 倍で、small モデルの $K = 5$ 並列サンプルと適応サンプリングで Antimony ブロックを多数書くことによる。RIKYU の 1 ノード（10 件を並列）で 3 run はそれぞれ約 31、58、81 分で終わった。react-luna の 1 件（BIOMD0000000231）は反復 17 で 60 分間出力が止まり、stall_timeout で打ち切ってやり直した（やり直しは約 10 分で完走）。候補 SBML の子プロセスの作り直しは autoscilab の 2 run とも 0 回だった。

7 考察

仮説条件付き獲得が効かなかった理由（c2）. 各件の trace から、ループの挙動を確かめた。1 件あたり 5 反復で、そのうち確信度が 0.9 を超えて Refine モードに入った反復は autoscilab-luna で平均 2.0 反復、アブレーションでも 2.0 反復だった。Refine モードではスコアがブートストラップ再フィット間の分散に替わるので、仮説集合の食い違いは使われない。残る Disambiguate モードの反復でも、仮説集合が 1 構造しか持たない反復が autoscilab-luna で平均 1.7 反復あり（アブレーションは 2.3 反復）、構造が 1 つなら食い違いスコアは全点 0 で、選択は多様性項だけになる。つまり、仮説条件付き獲得が実際に実験の選び方を変えたのは 5 反復のうち 1〜2 反復にとどまった。sanity で観察したとおり、上流の prompt は現在の最良仮説を見せる仕様で、small モデルが large と同じ gpt-6-luna だと同じ構造を返しやすく、エントロピーが早く 0 になる。論文が small モデルに別の、より弱いモデルを使っている（Qwen2.5-7B-Instruct (Kabra et al., 2026, s2.p4)）のは、この多様性の面で効いていた可能性がある。

フィットの質. 最良候補のフィット誤差（log 濃度の RMSE）が 1 を超えた件は autoscilab-luna で 4 件、アブレーションで 4 件あり、最終確信度が 0.9 以上だった件はどちらも 5 件だった。速度則を自由にしても、半分の件では候補が観測を再現できておらず、提出 SBML の STE はその件で高い。前研究で主因と判断した「3 型の文法」を外しても STE が ReAct に 及ばなかったのは、文法ではなく候補の定数フィットと仮説の選び方が律速になっていることを示す。ReAct 側は 10 件中 3 件（STE 0.719、0.327、0.265）が平均を押し上げ、残りの 7 件は 0.05 未満だった（各件の SciGym 評価より）。

構造の回復（c3）. 反応構造の回復（修飾子なしの RMS F1）では前研究と同じくループが ReAct を上回り、c3 は支持された。ReAct は 1 件あたり平均 10.9 回しか実験せず、残りの反復をコード実行と推論に使う。ループは 20 回の実験を全件で使い切り、候補をフィットして選ぶので、反応物と生成物の組み合わせ（構造）は当たりやすい一方、定数の当て方が悪く軌道誤差（STE）では負ける、という前研究と同じ型が 10 件でも再現した。修飾子ありの RMS F1 と NTS F1 の差は小さく、修飾子（速度則にだけ現れる種）の扱いは両者とも弱い。

統計的な力. 10 件での平均の差の標準誤差は 0.1 程度と見積もっており、c1・c2・c3 の差（+0.017、-0.011、-0.035）はいずれもこの幅の内側である。判定は規則どおり導いたが、支持・反証のどちらも偶然で説明できる範囲にあり、137 件での確認が要る。

移植の境界. 3 run の observed.json は、宣言した 6 つの拡張点（EnsembleAgent、HypothesisDistribution、ExperimentStore、OracleResult、BaseOracle、_JsonWorker）のサブクラスだけが上流を上書きし、monkeypatch（redefinitions）が無いことを記録している。上流の `run_round` と `select` が毎反復呼ばれたことも calls に残る。ReAct 側では、宣言していた OpenAI クライアントの `Completions.create` をフックがデコレータのラッパとしてしか記録せず、モデル名の宣言先を run 後に SciGym 公式の `LLM.__init__` の `model_name` に付け替えた（実験条件は同じで、run は再実行していない。記録の履歴に初回の宣言が残る）。

8 結論

LLM-AutoSciLab の公式モジュールを Antimony の仮説で SciGym に繋ぎ、速度則を自由にした上で、等間隔に選んだ 10 件で SciGym 公式 ReAct と比べた。平均 STE はループが ReAct より 0.017 高く（c1 反証）、構造の回復（RMS F1）ではループが 0.035 上回った（c3 支持）。速度則を自由にすると STE の差は前研究の 5 分の 1 以下に縮んだが、符号は変わらなかった。仮説条件付き獲得を外したアブレーションとの差は判定線に届かず（c2 反証）、trace からは、確信度の門と仮説の多様性の早い収束のために、食い違いスコアが実験の選び方を変えた反復が 5 反復中 1〜2 反復しかなかったことが分かった。この移植で手法の中核が働く条件を作るには、small モデルを主モデルと別にして多様性を保つか、適応サンプリングの停止則を緩める必要がある。いずれも上流の設定の範囲で試せる。

データの利用可能性

記録は record.json にある。実験コード、環境の固定（Dockerfile と `uv.lock`）、各 run の結果と provenance は同じリポジトリに含まれる。

References

Haonan Duan, Stephen Z. Lu, Caitlin F. Harrigan, Nishkrit Desai, Jiarui Lu, Michał Koziarski, Leonardo Cotta, and Chris J. Maddison. Measuring scientific capabilities of language models with a systems biology dry lab. *NeurIPS 2025*, 2025. doi: 10.48550/arXiv.2507.02083. URL `https://arxiv.org/pdf/2507.02083`. code: https://github.com/h4duan/SciGym at commit 88a7b93609e35b6ecb4eb343d816d6ff09256c6a.

Sanchit Kabra, Nikhil Abhyankar, Saaketh Desai, Prasad Iyer, and Chandan K. Reddy. Llm-autoscilab: Closed-loop scientific discovery via active experimentation with llms. *NeurIPS 2026*, 2026. URL `https://arxiv.org/pdf/2605.24043`. code: https://github.com/scientific-discovery/LLM-AutoSciLab at commit 351aae73e6c6c279e67943b77143b0f118d1e289.